



ALMA MATER STUDIORUM
UNIVERSITÀ DI BOLOGNA

CORSO DI LAUREA IN INGEGNERIA INFORMATICA

Metodi di applicazione del Copyright per contenuti generati con Intelligenza Artificiale

Relatore

Prof. Claudia Cevenini

Presentata da

Alessandro Querzè

Correlatore

Dott. Giorgio Franceschelli

Sessione di ottobre 2025

Anno Accademico 2025/2026

Indice

Introduzione	2
1. Definizione e applicazione del diritto d'autore.....	3
2. Comportamenti dei modelli attuali.....	4
2.1 Pipeline di training nei modelli testuali	4
2.2 Principi di funzionamento dei modelli generativi visivi.....	4
3. Ripercussioni legali dei modelli IA	9
4. Un diverso approccio al problema	10
5. Conclusioni.....	14
Ringraziamenti.....	16
Bibliografia e Sitografia	16
Normativa	18
Giurisprudenza.....	18

Introduzione

Con l'avanzamento tecnologico da parte delle intelligenze artificiali generative, diventa sempre più necessario trovare una quadra giuridica relativa a immagini e testi creati tramite questi strumenti, a chi appartengono, a quali leggi sono sottoposte e quali azioni è necessario intraprendere di fronte a questi nuovi strumenti, e questa tesi mira a costruire un'immagine più chiara delle attuali opzioni tecnologiche e scelte giuridiche attuabili.

Più nel dettaglio, verranno mostrati dal punto di vista tecnico i vari modelli di IA e le loro caratteristiche e i loro limiti riguardo l'ottenimento delle fonti utilizzate.

Successivamente si andrà ad analizzare eventuali strumenti esterni di analisi per sopperire alle mancanze di determinati modelli.

Dal punto di vista legale, infine, l'obiettivo è riassumere come è stato applicato il diritto d'autore rispetto a questi contenuti in passato e nel presente, comprendere come si sta evolvendo attualmente il panorama giuridico e quali prossime leggi o modifiche si stanno prendendo in considerazione.

1. Definizione e applicazione del diritto d'autore

Il diritto d'autore è l'insieme delle norme giuridiche che riconoscono e tutelano i diritti spettanti all'autore di un'opera dell'ingegno di carattere creativo. Questi diritti sorgono automaticamente al momento della creazione dell'opera, senza necessità di registrazione, e spettano al creatore insieme ad eventuali coautori.

Nello specifico, il diritto d'autore è diviso in due categorie:

diritti morali e diritti patrimoniali. I primi sono relativi alla morale e alla dignità dell'autore ed eventuali attori che performano tali opere, gli ultimi, invece, definiscono i diritti della sfera economica riguardanti una determinata opera.

In Italia, gli articoli relativi al diritto d'autore sono contenuti sia nel Codice civile (artt. 2575–2583) sia nella Legge 22 aprile 1941 n. 633, che definisce durata, modalità di esercizio, eccezioni e sanzioni.

Il campo di applicazione del diritto d'autore è molto ampio e include qualsiasi creazione che presenti un carattere creativo, nel nostro caso, si analizzerà il campo delle immagini.

2. Comportamenti dei modelli attuali

2.1 Pipeline di training nei modelli testuali

L'addestramento dei modelli linguistici di grandi dimensioni (LLM) può essere suddiviso in tre fasi. La prima fase prevede la raccolta e l'elaborazione dei dati.

La seconda fase comprende determinazione dell'architettura del modello e le attività di pre-addestramento, nonché l'utilizzo di algoritmi paralleli adeguati a completare l'addestramento effettivo.

La terza fase prevede la messa a punto (fine tuning) e l'allineamento. [1]

Quando un LLM produce un testo, quello che succede è che ogni parola viene selezionata da una serie di parole che sono le più statisticamente probabili; per raggiungere un elevato livello di accuratezza, i modelli attuali, spezzando in token distinti le parole, elaborano l'intera frase con l'ausilio di una serie di attention blocks [2], che permettono di estrarre il significato concettuale di ogni singolo token, in base al contesto fornito dai token precedenti.

Ognuno di questi token è dunque rappresentabile come un punto in uno spazio vettoriale (di cui si parlerà più avanti), e un intero testo è rappresentabile come una polilinea composta dai suoi token.

2.2 Principi di funzionamento dei modelli generativi visivi

La storia dell'essere umano che cerca di costruire immagini risale a tempi ormai antichi; infatti, già nel 1950 esistevano già i primi algoritmi in grado di generare arte procedurale, di cui i frattali sono un perfetto esempio.

Tuttavia, risultati concreti nel ricreare immagini complesse, come persone e oggetti, sono arrivati relativamente di recente: le GANs (Generative Adversarial Networks) furono le prime

a ottenere risultati importanti nella ricreazione più o meno fedele di questi ultimi contenuti “astratti ma complessi”

Il funzionamento di queste network, introdotte nel 2014 da Ian J. Goodfellow [3] è, molto semplificato, spiegabile introducendo due reti neurali; Il Generatore (G) e il Discriminatore (D), il compito delle due è competitivo, ovvero la rete Generatore cercherà di creare immagini che passino il controllo del Discriminatore, mentre il Discriminatore dovrà asserire se la foto in questione è una immagine vera (presente nel dataset) o false, ergo prodotta dalla rete Generatore. Le due reti ovviamente inizialmente saranno molto scarse, ma con sufficienti iterazioni si sono riscontrati risultati rimarchevoli.

Lo svantaggio principale che ha causato la dismissione attuale dal mercato di queste reti non era la qualità delle immagini, quanto più una difficoltà generale nello scalare l’addestramento, nella capacità di “creatività” limitate (le immagini erano di alta qualità ma solo se rimanevano sufficientemente fedeli al dataset), e la mancanza di robustezza intrinseca dell’architettura.

Concentrandoci quindi sui modelli attuali, la tecnologia attualmente più diffusa sono i diffusion-based models.

In poche righe, un diffusion based model ottiene una serie di token testuali (il prompt), vengono trasformati tramite un encoder in un vettore per lo “spazio degli embedding” che rappresenta il concetto della frase, a questo punto un denoiser, tramite il processo di diffusione (da cui prendono il nome questi modelli) cerca, partendo da una condizione di caos, di predire il rumore(noise) da rimuovere, utilizzando come riferimento il precedente citato vettore, tramite meccanismi di cross-attention.

Infine, un decoder si occupa di estrarre il vettore risultante dallo spazio degli embedding e trasformarlo in pixel.

Analizzando più nel dettaglio le varie parti, è opportuno soffermarsi sullo spazio degli embedding, o più in generale, sugli spazi latenti usati dai modelli di IA attuale.

Uno spazio latente è uno spazio matematico multidimensionale dove sono rappresentati vettori a più componenti, dove ogni componente rappresenta il valore di una dimensione in questo spazio.

Gli spazi latenti vengono utilizzati per rappresentare e manipolare dati e informazioni; possono variare come “significato concettuale”, e in certi casi un modello può possedere più di un singolo spazio latente:

Prendendo come esempio Stable Diffusion, questo modello utilizza due spazi latenti:

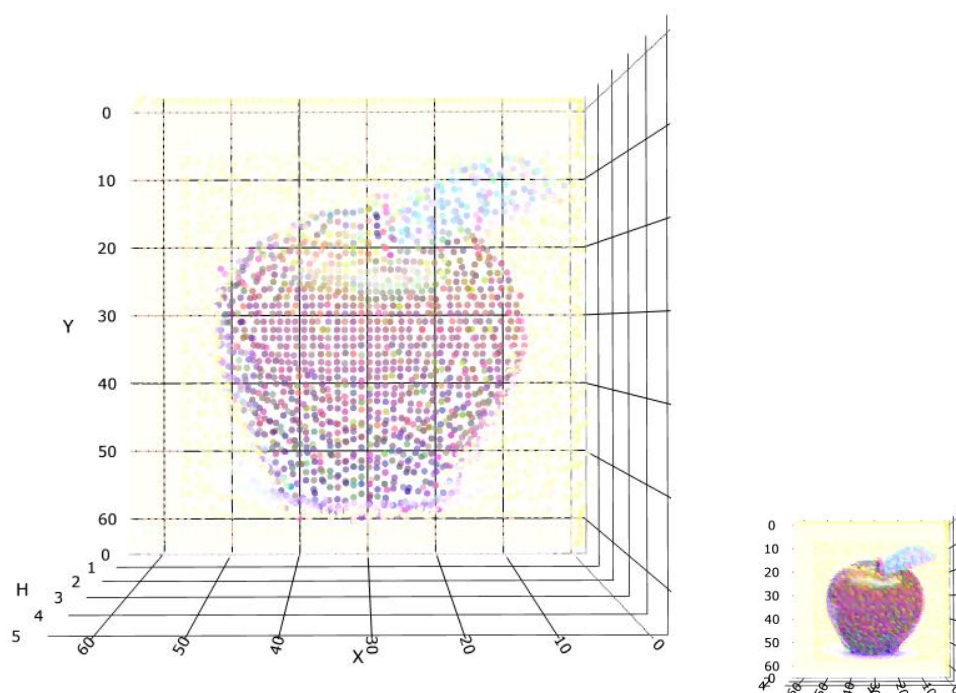
(a) Lo spazio delle immagini:

Questo è uno spazio $4 \times 64 \times 64$. In esso non sono presenti veri e propri “concetti”, solo una compressione dell’immagine originale (le 64×64 dimensioni) con quattro canali (le restanti 4) che rappresentano contenuti visivi come texture, forme, strutture.

Tuttavia, le informazioni non vengono manipolate ancora a tal punto da risultare irriconoscibili: è infatti possibile plottare questi vettori immagine e si noterà una certa somiglianza con l’immagine originale, seppur compressa:



Immagine di una mela, $512 \times 512 \times 3$ dimensioni (512×512 pixels, tre canali RGB)



Stessa immagine nello spazio latente di SD, 4x64x64 vista dall'alto, i 4 canali non rappresentano la colorazione RGB, ma hanno una correlazione rimarcabile

(b) Lo spazio degli embedding testuali:

Questo spazio invece è rappresentato da 768 o 1280 dimensioni, dove, contrariamente allo spazio delle immagini, vengono compressi anche i significati semantici. Questo spazio vettoriale viene fornito da una parte di CLIP, strumento che verrà analizzato successivamente.

Entrambi gli spazi vengono generati grazie a specifici training. Per quanto concerne lo spazio delle immagini di Stable Diffusion, viene utilizzato un Variational Autoencoder (VAE) che impara in maniera auto-supervisionato (senza intervento umano) a comprimere e decomprimere le immagini.

Successivamente, grazie a una U-net [4], i due spazi vengono correlati tramite il meccanismo di “cross-attention” per ottenere il risultato richiesto dall’utente tramite prompt testuale.

Passando invece al modello di CLIP (Contrastive Language–Image Pretraining):

CLIP è uno strumento in grado effettuare l'encoding di testo, immagini, e immagini con testo(descrizione) in un singolo spazio latente.

Quello che è in grado di fare, è inserire in uno spazio latente di 512 dimensioni i vettori rappresentativi di immagini e testo e posizionarli in base non solo alle loro feature visive, come succede in Stable Diffusion, ma anche in base al loro “significato” vero e proprio.

La distanza concettuale (in relazione al modello) quindi tra due immagini o testi potrà essere verificata tramite il metodo della cosine similarity, che fornisce una distanza angolare tra due vettori.

Inoltre, grazie al metodo del contrastive learning [5], CLIP è anche in grado di associare i vettori testuali ai vettori immagine, posizionando vettori che hanno significato “intrinseco” simile vicini tra loro, mentre vettori con significati dissimili lontani. È opportuno specificare che è un approccio relativo e non assoluto; infatti, solitamente i vettori testuali e di immagini anche con significato quasi identico (la foto di un gatto generico e il testo “cat”) saranno comunque particolarmente distanti, la capacità di CLIP è di fare in modo che i vettori con significato diverso da quello delle immagini siano più lontani di quelli con significato simile.

Clip da solo è solo in grado di effettuare un encoding, quindi una codifica. Per estrarre immagini da questo spazio latente è dunque necessario utilizzare altri strumenti, come ad esempio unCLIP [6], che diventerà poi noto come DALL-E 2.

Il funzionamento di DALL-E 2 per quanto concerne la generazione di immagini è concettualmente simile a quello di Stable Diffusion, l'unica differenza rilevante è che in questo caso, lo spazio in questione è unico e non più separato in due, uno per l'embedding di testi e l'altro per l'embedding di immagini.

Per ottenere questi modelli, è necessario eseguire algoritmi di training per regolare i “pesi” all'interno di questi ultimi, che sono in ultima analisi i parametri utilizzati da questi sistemi per effettivamente comprendere come rappresentare i contenuti e concetti all'interno degli spazi latenti.

Per questi algoritmi di training, sono necessarie grandissime quantità di informazioni, testuali o grafiche, che spesso si trovano nei cosiddetti “Dataset”, collezioni di dati ordinati o meno, i

cui elementi sono spesso ottenuti tramite web scraping e con impossibilità di controllo granulare, vista l'incredibile mole di informazioni.

3. Ripercussioni legali dei modelli IA

Con il rapido progresso dei modelli di intelligenza artificiale generativa basati sul deep learning vengono sempre più sollevati interrogativi sullo stato del copyright delle opere generate dall'IA e sulla possibilità che si verifichi una violazione quando tali sistemi vengono addestrati e utilizzati. Tra questi rientrano modelli di conversione da testo a immagine come Stable Diffusion e modelli linguistici di grandi dimensioni come ChatGPT. Nel 2023, erano pendenti diverse cause legali negli Stati Uniti che contestavano l'uso di dati protetti da copyright per addestrare modelli di IA, con gli imputati che sostenevano che ciò rientrava nel fair use [7]; Tuttavia, già all'epoca delle GANs [3] sorsero i primi problemi dal punto di vista della legge: queste immagini, infatti, erano in grado di generare immagini sufficientemente "coerenti" a certi temi da causare azioni legali da parte di aziende importanti come la Disney e l'Universal per violazione di diritto d'autore relativo a certe opere proprietarie, portando alle prime lettere di cease & desist relative a questo argomento.

Per evidenziare l'importanza del problema è utile analizzare a fondo gli ultimi anni, dal 2023 in poi, si registrano infatti, tra le più note cause legali, esempi come l'accusa del New York Times contro Microsoft e OpenAI di aver utilizzato alcuni dei loro contenuti prodotti da copyright[8], e non solo: venne sottolineato un'altra considerazione molto rilevante quale la capacità di questi modelli di superare i paywall dei giornali online, rendendo l'attività giornalistica indipendente, secondo il New York Times, molto più ardua economicamente. Un altro caso giuridico rilevante alla generazione di testo è la class action di Authors Guild e vari altri autori sempre contro OpenAI e Microsoft, presentante come accuse generali una importante rilevanza dei testi protetti nel garantire dati di qualità e una capacità non quantificabile da persone esterne di poter memorizzare e riutilizzare parti protette da copyright da parte di questi modelli; Nello specifico, le violazioni contestate sono il *direct copyright infringement*, il *vicarious copyright infringement* e il *contributory copyright infringement* [9], è opportuno sottolineare la differenza tra leggi statunitensi e europee/italiane, pur riconoscendo

le similarità tra queste ultime e le leggi sul diritto d'autore n. 633/41 [10] (art 13–19bis), e la direttiva europea 2001/29 [11] (art 3,4,5).

Considerando i casi relativi alle immagini, invece, troviamo, oltre al già citato caso dell'Universal & Disney, appelli come Getty Images v. Stability AI, sia in territorio statunitense [12] che britannico [13] e il Andersen et al. v. Stability AI Ltd., et al. [14]

In tutti questi esempi, le principali accuse riguardano l'accesso non autorizzato di immagini protette da copyright per l'allenamento di questi prodotti. Nell'istanza del caso Andersen, viene anche sottolineato come i modelli non siano in grado di generare contenuti completamente nuovi ma solo di interpolare immagini nel dataset; questo era probabilmente vero all'epoca dell'accusa, tuttavia oggi le capacità generative sono significativamente migliorate.

4. Un diverso approccio al problema

Basandoci sull'attuale difficoltà nel ricostruire con precisione i contributi singoli nella generazione di immagine, si propone una diversa interpretazione dei meccanismi di attribuzione del significato nello spazio degli embedding.

Per semplicità verrà preso in considerazione il modello CLIP, che in un solo spazio è in grado di rappresentare le immagini in maniera “concettuale”.

Una comprensione qualitativa di come i contenuti vengano organizzati nello spazio latente di CLIP può essere ottenuta analizzando le prestazioni di modelli generativi (DALL-E), nella produzione di immagini che riflettono significati complessi.

Tale analisi risulta particolarmente interessante nel momento in cui al modello viene richiesto di integrare concetti tra loro vettorialmente molto distanti: nonostante la loro eterogeneità, l'immagine generata risulta coerente e riconoscibile. Questo comportamento costituisce un'indicazione significativa che la rappresentazione latente non si limita a un'associazione superficiale, ma riflette una comprensione “semantica” dei contenuti presenti in un'immagine.

Al termine del training di un modello, è possibile reinserire tutti gli elementi del dataset in CLIP per ottenere la posizione vettoriale di ciascuno di essi. In tal modo, il risultato sarà un elenco di punti rappresentativi del dataset iniziale nello spazio del modello.

A seguito di questa operazione, data una nuova immagine generata a partire da questo spazio, è possibile reinserire anche questa per ottenerne la posizione nello spazio latente.

Analizzandone la posizione in relazione all'elenco di punti del dataset originale, essa si troverà ragionevolmente più vicina a immagini col significato "concettuale" più simile.


Per spiegare tale risultato, è opportuno suddividere i possibili passaggi effettuati dal modello in due possibili ipotesi:

ipotesi A: dato un punto P nello spazio vettoriale, se in un intorno sufficientemente piccolo C ci sufficienti immagini N, è possibile considerare il modello di IA come un interpolatore di immagini non lineare, questo partendo dalla considerazione che avendo sufficienti esempi il modello non abbia necessità di mettere insieme parti di immagine non differenti tra loro

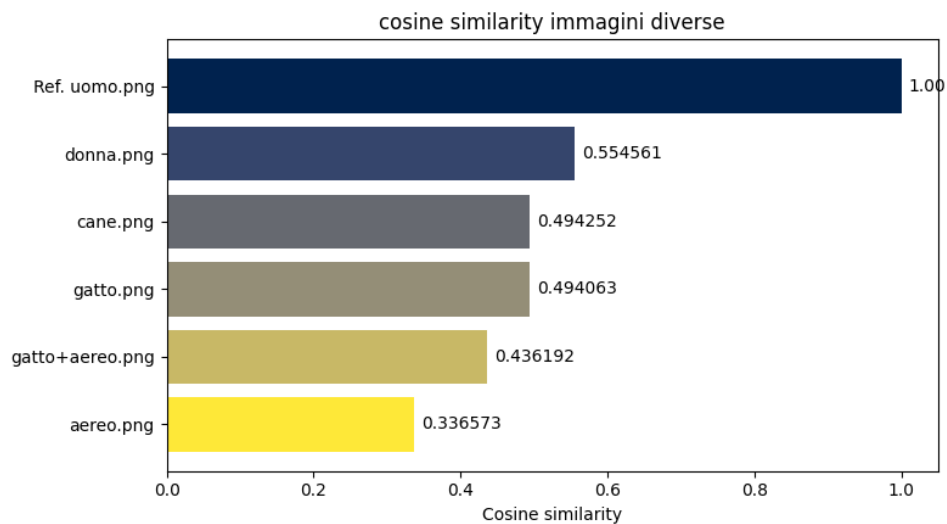
ipotesi B: se le condizioni dell'ipotesi A non si verificano, allora è sensato ipotizzare che siano stati messi insieme significati (quindi vettori) appartenenti a regioni dello spazio vettoriale non vicine. Questo implica a sua volta due cose: la prima, il vettore risultante sarà per forza di cose distante da almeno uno degli N vettori; la seconda, per riottenere correttamente tutte le immagini che hanno contribuito a questa specifica generazione, non basta analizzare la regione di spazio del vettore finale risultante, ma è necessario esaminare e scomporre l'immagine (analizzare il vettore sarebbe più efficiente ma ad oggi non disponiamo ancora di tecnologie adeguate a questo compito) ottenuta in vettori base che la definiscono, dal punto di vista pratico: soggetti, stile artistico, posizionamento spaziale ecc; gli elementi individuabili sono numerosi, ma ciascuno può essere descritto in modo chiaro e circoscritto.

Per analizzare un'immagine esistono tutt'ora numerosi strumenti: i modelli commerciali sono in grado, nella maggioranza dei casi, di fornire una descrizione accurata di un'immagine; esistono inoltre strumenti utilizzabili in ambito di programmazione per la generazione automatica di descrizioni (caption, in inglese) come ad esempio BLIP, che verrà menzionato brevemente più avanti.

Esaminando concretamente l'ipotesi A sono stati effettuati dei test:



Distanza tra un'immagine generica di gatto e diverse immagini, usato il metodo di misurazione cosine similarity



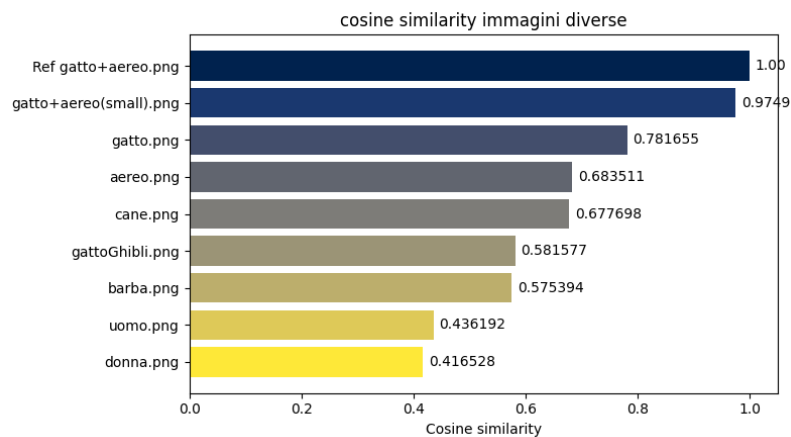
Distanza tra un'immagine generica di uomo e diverse immagini, usato il metodo di misurazione cosine similarity

Come è possibile notare, il modello è in grado di differenziare correttamente il contenuto delle immagini con granulare approssimazione (come, ad esempio, la sottile distanza tra cane e gatto rispetto alla distanza con uomo)


Dal punto di vista dell'ipotesi B, è stato inizialmente utilizzato BLIP per generare caption testuali; tuttavia, il modello non ha prodotto risultati soddisfacenti.

È stato poi tentato un approccio di analisi caption-immagine; tuttavia, anche qui è stato riscontrata una inefficacia nel modello CLIP di distinguere il caption corretto in presenza di immagini complesse.

Risultati coerenti sono invece stati riscontrati quando si sono paragonate immagini simili ma diverse fra loro: il modello CLIP è stato in grado di raccogliere dettagli fini nelle immagini e distanziarle fra loro correttamente.



Distanza tra un'immagine generica di una foto con soggetti un gatto e un aereo e immagini simili



Distanza tra un'immagine generica di un uomo e immagini simili



Alcune immagini di riferimento

Come visibile, il modello è stato in grado di rilevare differenze sia di contenuto che di proporzioni spaziali, questo suggerisce che per effettuare un'analisi corretta sarebbe opportuno o cambiare modello di encoding, oppure trasformare i vettori testuali che compongono l'opera contenutisticamente in vettori immagine, ricordando come essi siano matematicamente nello stesso spazio ma abbiano strutture sufficientemente differenti da risultare troppo distanti l'uno dall'altro quando comparati tra loro tramite il metodo di cosine similarity.

5. Conclusioni

Pur essendoci differenze nella formulazione delle leggi e delle conseguenze sulle loro violazioni, è generalizzabile il postulato che l'uso di opere protette da copyright da parte delle piattaforme commerciali per l'apprendimento automatico costituisce una violazione, a meno che la piattaforma non abbia utilizzato opere concesse in licenza o non protette.

Allo stesso modo, si verifica violazione anche da parte dell'utente utilizzatore qualvolta l'algoritmo dovesse restituire un'immagine non dissimile ad una già esistente e protetta. [15]

Nel contesto specifico italiano, la violazione riguarderebbe in entrambi i casi la violazione dell'articolo 13 della legge 633/41. [10]

Inoltre, perlomeno in Italia si pone anche il problema dei diritti morali: in certi casi un autore potrebbe non voler avere la propria opera riprodotta, in accordo con i suoi diritti (legge 633/41, artt. 20-24), in quel caso dovrebbero essere vigenti controlli più stretti per assicurarsi una rimozione forzata di tali prodotti.

È importante sottolineare anche come il diritto d'autore sia stato strutturato appositamente come vago e non chiaramente delimitato da confini, questo in passato rappresentava un punto di forza, poiché così era più difficile trovare modi per sviarlo. Ora, con le intelligenze artificiali, questo punto di forza si è trasformato in un appiglio di incertezza sfruttato dai provider di IA.

Ovviamente il problema più grande si pone ove le situazioni sono più sfumate, ovvero dove non ci sia una chiara origine delle risorse utilizzate o le immagini in output del modello non siano riconducibili chiaramente a immagini già esistenti.

Proprio per questo stanno venendo varate in tutto il mondo leggi per coprire queste nuove tematiche, osservando il territorio europeo, infatti, già nel 2024 è stato emanato il regolamento

europeo 2024/1689, chiamato anche “AI Act”, in cui sono state definite regole generali per tutti gli aspetti delle intelligenze artificiali, dalla sicurezza, a quali campi possono coprire e non coprire, a informazioni specifiche sul copyright: la direzione europea è infatti caratterizzata da una politica di “opt-out”, cioè la possibilità da parte degli autori di richiedere esplicitamente di non utilizzare le proprie opere come parte del training. Viene citato inoltre come sia necessario dai provider fornire in modo trasparente le origini dei dati utilizzati, che siano essi elementi di determinati dataset, siti o similari.

Muovendosi invece sulle regioni orientali, di rilevante importanza la decisione giapponese di effettivamente garantire un nulla osta nell'utilizzo di qualunque immagine a fini di training e data mining, anche protetta, purché non vada a intaccarne la vendita commerciale (art 30-4), segnando un grosso contrasto con le politiche del resto del mondo [16], mentre la Cina ha deciso di adottare misure vicine a quelle europee, tutelando ed esigendo trasparenza nell'utilizzo delle fonti. [17]

È giusto indicare velocemente come già inizino a sorgere metodi per circoscrivere il web scraping da parte di algoritmi e IA utilizzabili dagli autori, come il file “robots.txt”, tecnica che consiste nel permettere e impedire la navigazione automatica di determinate risorse presenti su un sito web, con eventuali sistemi di sicurezza in caso queste regole vengano violate, come le spider trap. [18]

Tali sistemi non sono ancora stati usati nell'ambito delle immagini e sarebbe difficile se non impossibile attuare sistemi di sicurezza come le spider trap nei siti web vista la natura “semplice” delle immagini, ma potrebbero rappresentare un avanzamento nella tutela delle opere online da parte di enti regolamentati.

In questo documento, viene mostrato come è possibile analizzare il significato concettuale di una data immagine rispetto a un determinato modello, offrendo come possibilità l'utilizzo di questo strumento per, in futuro, effettuare una selezione iniziale delle immagini candidate ad aver contribuito, almeno parzialmente, alla creazione dell'immagine, oltre a fornire uno strumento per l'identificazione automatica di immagini originali del dataset grazie alla reimmissione di queste nel modello stesso, come accennato nel capitolo 4 (utilizzando sempre lo strumento di cosine similarity, è possibile mettere a disposizione una API che permette di

verificarne il valore per una data immagine, e dove questa sia 1.00 si avrebbe una corrispondenza diretta tra immagine inserita e una data immagine nel dataset di training).

Viene anche accennata la possibile strada relativa alla scomposizione in parti semplici dell'immagine; tuttavia, dato il numero non sufficientemente alto di campioni (sarebbero necessarie milioni di immagini per confermare risultati statistici rilevanti) è corretto pensare a strumenti più fini per un'analisi di questo tipo, che sicuramente con l'avanzare della complessità di sistemi di AI generative sarà sempre più necessaria.

Ringraziamenti

Ringrazio i miei relatori per il supporto e per la possibilità di approfondire e spiegare questo tema a me caro,

Altrettanto ringrazio la mia famiglia e i miei amici per il supporto nell'adempimento di questo percorso, senza i quali non sarei riuscito ad arrivare ai risultati che ho raggiunto.

Bibliografia e Sitografia

[1] Understanding LLMs: A Comprehensive Overview from Training to Inference,
<https://arxiv.org/pdf/2401.02038v2>

[2] Attention Is All You Need,
<https://arxiv.org/pdf/1706.03762>

[3] Ian J. Goodfellow, “Generative Adversarial Nets”,
https://papers.nips.cc/paper_files/paper/2014/file/f033ed80deb0234979a61f95710dbe25-Paper.pdf

[4] U-Net: Convolutional Networks for Biomedical Image Segmentation,
<https://arxiv.org/pdf/1505.04597>

[5] Learning Transferable Visual Models From Natural Language Supervision,
<https://arxiv.org/pdf/2103.00020>

[6] Hierarchical Text-Conditional Image Generation with CLIP Latents,
<https://cdn.openai.com/papers/dall-e-2.pdf>

[15] Azrights International Ltd "What is the Copyright Status of AI Generated Works?",
<https://www.linkedin.com/pulse/what-copyright-status-ai-generated-works-azrightsinternational>

[18] Margaret Rouse, “What is a Spider Trap?”,
<https://www.techopedia.com/definition/5197/spider-trap>

Normativa

[10] Legge 633/41, Normattiva,

<https://www.normattiva.it/esporta/attoCompleto?atto.dataPubblicazioneGazzetta=1941-07-16&atto.codiceRedazionale=041U0633>

[11] Direttiva 2001/29, Eur-Lex,

<https://eur-lex.europa.eu/eli/dir/2001/29/oj/ita>

[16] Copyright law of Japan,

https://www.cric.or.jp/english/clj/doc/20210624_law.pdf

[17] Interim Measures for the Management of Generative Artificial Intelligence Services
[translation],

<https://www.airuniversity.af.edu/Portals/10/CASI/documents/Translations/2023-08-07 ITOW Interim Measures for the Management of Generative Artificial Intelligence Services.pdf>

Giurisprudenza

[7] Ahmad, Ariba A; Gross, Andrew M. "Generative AI Systems Tee Up Fair Use Fight",

<https://natlawreview.com/article/generative-ai-systems-tee-fair-use-fight>

[8] NYT v. OpenAI: The Times's About-Face,

<https://harvardlawreview.org/blog/2024/04/nyt-v-openai-the-timess-about-face/>

[9] Authors Guild v. OpenAI, Inc., et al., n. 1:23-cv-08292 (S.D.N.Y., 19 Settembre 2023),

<https://authorsguild.org/app/uploads/2023/12/Authors-Guild-OpenAI-Microsoft-Class-Action-Complaint-Dec-2023.pdf>

[12] Getty Images (US), Inc. v. Stability AI, Inc, [reproduction of federal docket],

<https://docs.justia.com/cases/federal/district-courts/delaware/dedce/1%3A2023cv00135/81407/1>

[13] Getty Images (UK), Inc. v. Stability AI, Inc,

<https://www.judiciary.uk/wp-content/uploads/2025/01/Getty-Images-and-others-v-Stability-AI-14.01.25.pdf>

[14] Andersen et al. v. Stability AI Ltd., et al., [reproduction of federal docket],

<https://storage.courtlistener.com/recap/gov.uscourts.cand.407208/gov.uscourts.cand.407208.1.0.pdf>